SECTION 1 | LECTURE 3

통제 4축 기준 잡기: 비용 · 품질 · 리스크 · 흐름

AI 애플리케이션을 보는 공통 판단 프레임 만들기.
막연한 자동화의 환상에서 벗어나 4개의 명시적 아키텍처 축으로 시스템을 지배합니다.

AXIS 01	AXIS 02	AXIS 03	AXIS 04
COST	QUALITY	RISK	FLOW

똑같은 장애 요청도 네 가지 문제로 나뉜다

03:00 INCIDENT REQUEST

"서비스 X의 500 에러 원인 분석 및 긴급 대응 브리프 정리 요청"



01. COST ISSUE

호출 비용 폭주

불필요하게 긴 로그 읽기, 무제한 루프 생성으로 API 자원 낭비

02. QUALITY ISSUE

답변 신뢰성 난조

포맷 비일관성, 원천 데이터(런북) 정합성 유실 및 환각 증세

03. RISK ISSUE

위험한 대응 추천 노출

근거가 불충분한 롤백·재시작 권고가 위험도와 승인 필요 여부 없이 전달

04. FLOW ISSUE

의사결정 우회

순서와 분기 규칙 없는 비선형 호출, 사후 디버깅 완전 차단

비용: 얼마나 많이 호출하고 비싸게 쓰는가

비용 축은 단순히 API 요금만을 뜻하지 않습니다. **시스템 지연 시간과 누적 지표** 전체를 지탱하는 뼈대입니다.

Input / Output Tokens

매 호출마다 LLM 컨텍스트에 담기는 불필요한 빅데이터 누수 차단

`Context Sizing Control`

Total API Calls

하나의 요청 과정 안에서 유발되는 LLM 내부 백엔드 연동 횟수 관리

`Call Rate Limiting`

Accumulated Latency

사용자가 장애 대응 현장에서 겪게 되는 최종 응답 대기 시간 조율

`Fast Classification Path`

Infinite Retry Loops

검증 실패 시 무차별적인 self-correction 루프가 돌면서 자원을 태우는 현상 제한

`Hard Loop Breakers`

품질과 리스크: 맞는 답과 안전한 답은 다르다

QUALITY AXIS (품질 축)

신뢰 정합성 지표

답변이 도메인 관점에서 얼마나 충실하고 유효한지 검증하는 영역

- **Format Stability:** 스키마(JSON 등)에 단 1byte 오차 없이 부합하는가
- **Evidence Alignment:** 공급받은 런북 컨텍스트 범위에 잘 안착해 있는가
- **Action Validity:** 조언하는 명령어의 형식이 사내 인프라 표준과 일치하는가

RISK AXIS (리스크 축)

안전 통제 가드레일

성능이 좋아 보여도, 한 치의 치명적인 사고 위협이 없는지 점검하는 영역성능이 좋아 보여도, 위험한 대응 추천이 운영 판단을 왜곡하지 않는지 점검하는 영역

- **위험 추천 식별:** 롤백·재시작·스케일 변경처럼 영향이 큰 대응 권고를 분류하고 위험도를 표시
- **승인 필요 여부 명시:** 운영 영향이 큰 추천에는 수동 검토와 승인이 필요함을 함께 전달
- **서비스별 정책 반영:** 서비스 중요도와 최소 심각도를 반영해 적절한 에스컬레이션 수준을 결정

흐름: 요청을 어떤 경로로 흘려보낼지 설계하는 문제

흐름은 단순히 사후 트레이스를 추적(Observability)하는 결과물이 아닙니다. **애초에 통제 가능한 처리 경로를 조각하는 패턴**입니다.

UNCONTROLLED FLOW (혼란형 블랙박스)

비선형적 체이닝

구체적인 분기 조건 없이 모델 자율 판단(ReAct)에만 의존하여 무한 루프나 탐색 실패를 유발하는 경로.

User → LLM Loop → Unchecked Run

CONTROLLED FLOW (의도된 아키텍처 경로)

명시적 순서 & 분기 가이드

사전에 정의된 정책 기반 분기, 최대 반복 횟수 명시, 위험 게이트 통과를 아키텍처 레이어 단위로 정교하게 매핑한 구조.

Router → Gate check → Evaluator

이번 Part 1은 네 축을 이렇게 풀어간다

Control Axis	Core Problems	Lecture / Section Match (솔루션)
COST	컨텍스트 낭비, 비효율적 토큰 소모	**Observability, Langfuse**(Tracer Flow 설계)
FLOW	비선형적 호출 루프 방지	**Routing Workflow**(호출 최적 분기 설계)
QUALITY	그럴듯하지만 틀린 환각 응답	**DTO Mapping, Validation, Evaluator-Optimizer**
RISK	위험한 대응 추천 노출	**위험도 분류, 승인 필요 여부 표시, 서비스별 에스컬레이션 정책, Orchestrator–Workers 역할 분리**

오늘 정리 & 다음 수업 안내

TODAY SUMMARY

통제 4축 핵심 이론 완결

- **명확한 설계 기준:** 통제는 막연한 감각이 아니라 비용·품질·리스크·흐름이라는 4개의 명시적 아키텍처 축으로 계측합니다.
- **품질 vs 리스크 분리:** "그럴듯하고 맞는 답"과 "사고가 없는 안전한 답"은 통제 레이어 자체가 다릅니다.
- **흐름 통제의 본질:** 사후적인 복기가 목적이 아닙니다. 요청 처리 경로 자체를 애초에 가이드하는 제약조건 설계입니다.

#control_4_axes #cost_quality_risk_flow #enterprise_patterns

UP NEXT LECTURE

다음 세션 미리보기

이제 통제 4축에 대한 개념 정립이 되었습니다. 다음 수업에서는 이 4축을 실제로 담아낼 Spring AI, Observability, Langfuse 통합 백엔드 기술 생태계를 해부합니다.

LECTURE 4 TOPIC

Spring AI · Observability · Langfuse 스택 큰 그림 보기

Move to Next Lecture