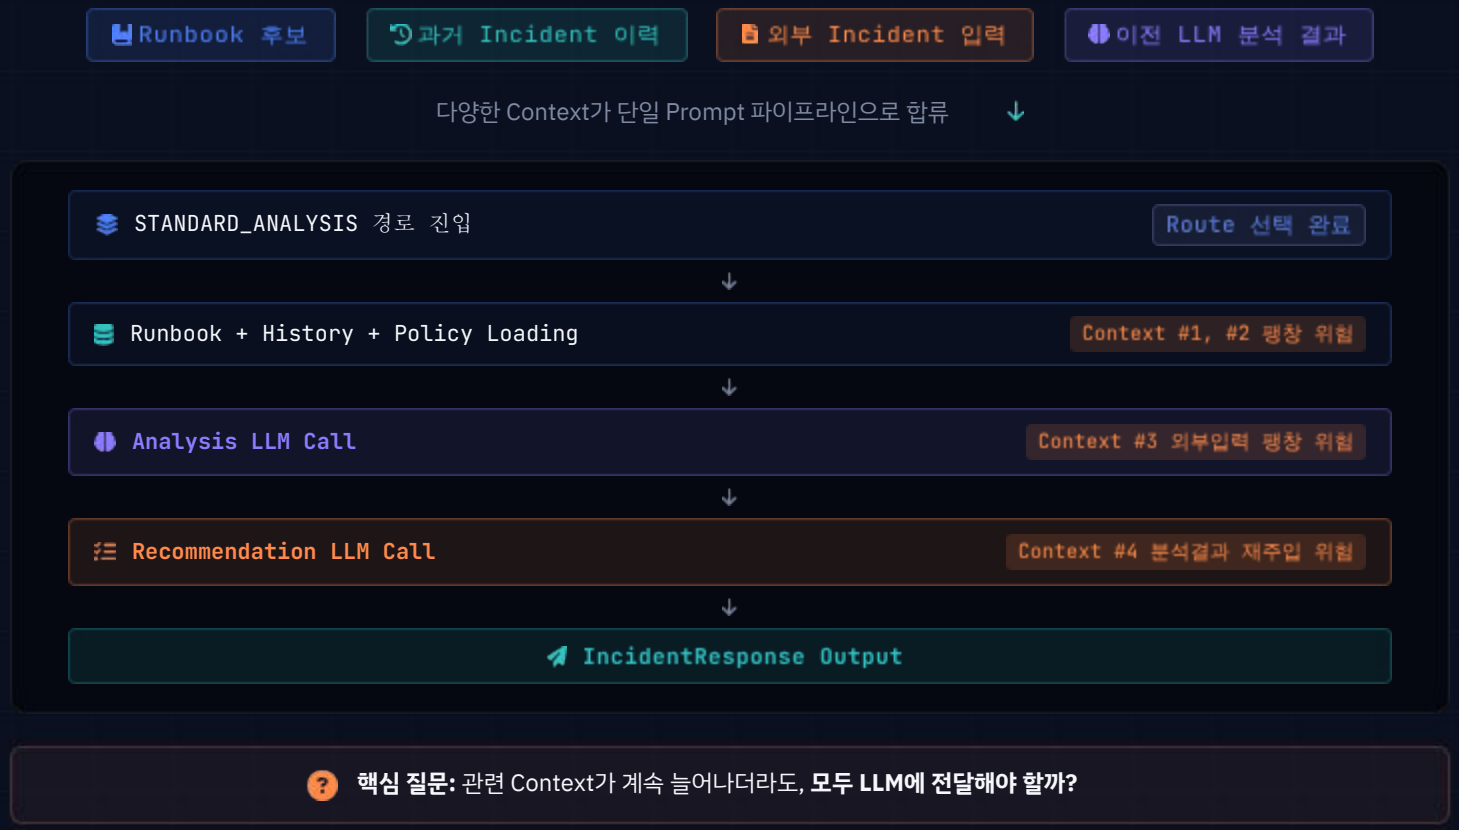
SECTION 4 | LECTURE 10

수업 10. 숨어 있던 비용 문제 개선하기

관련 데이터는 찾고, 전달량은 통제하기

Routing 이후의 과제: 남아 있는 비용 문제



핵심 질문: 관련 Context가 계속 늘어나더라도, **모두 LLM에 전달해야 할까?**

데이터 축적의 역설: Prompt 크기 동반 팽창

STAGE 01 운영 지속

데이터의 자연 축적

서비스가 운영됨에 따라 새로운 Runbook과 과거 Incident 이력 데이터가 지속 누적됨

- **Runbook 추가:** 신규 시스템 장애 대응 지침 지속 생성
- **History 누적:** 유사 장애 케이스 해결 이력 DB 축적
- **자연스러운 현상:** 문자열을 억지로 늘린 것이 아닌 정상 운영

관련 검색 후보군 증가

STAGE 02 상한 없는 전달

Prompt Context 비대화

전달량 상한 정책이 부재하면 조회된 모든 후보가 Prompt에 무제한 결합됨

- **무차별 바인딩:** 관련도 순위와 관계없이 전체 목록 전달
- **중복 정보 누적:** 동일 문제군의 유사 Runbook 중복 유입
- **외부 입력 방치:** 긴 summary 및 이전 LLM 출력 무검증 재주입

Prompt Context 동반 팽창

STAGE 03 비용 폭증

Input Token 급증

데이터가 작을 때는 보이지 않던 비효율이 운영 규모에서 심각한 비용 문제로 전환됨

- **Token 소비 가속:** 매 호출마다 수천 개의 불필요한 토큰 소모
- **대기 시간 연장:** 대용량 입력 처리에 따른 모델 Latency 증가
- **관심 분산:** 긴 Context로 인한 모델의 핵심 근거 집중도 저하

운영 위험 및 비용 증가

> **비용 설계 핵심 원칙:** 문제는 데이터가 많다는 것이 아니라 **전달량에 상한이 없는 구조**입니다.

관련 데이터 찾기 ≠ 관련 데이터 모두 보내기

맞춤형 통제 정책: Context 성격별 예산 설계

SELECTION BUDGET **선택량 통제**

선택 가능한 내부 Context

앱 내부에서 관리되며 작은 의미 단위로 정제된 데이터는 문자열 절단 대신 개수 상한을 적용

Runbook Context

- **중복 제거:** 동일 문제군 중복 제거 (Semantic Grouping)
- **상한 통제:** severity별 최대 개수(Top N) 상한 적용

History Context

- **순위 보존:** 기존 유사도 점수 기반 우선순위 유지
- **상한 통제:** severity별 상위 최대 건수(Top N)만 선별 전달

의미 단위를 손상하지 않는 개수(Top N) 상한 정책

SIZE BUDGET **크기 통제**

크기를 신뢰하기 어려운 Context

외부 사용자 입력이나 LLM의 생성 텍스트는 길이가 예측 불가능하므로 최대 길이 상한을 적용

Incident 외부 입력

- **입력 크기 제어:** title, summary, symptoms 등 외부 입력에 최대 길이 적용
- **Hard Limit:** 예상보다 긴 입력이 Prompt를 무제한으로 키우지 않도록 문자 수 상한 적용

Analysis Result → Action 재주입

- **출력 재주입 제어:** 1차 LLM의 출력도 2차 LLM에서는 다시 입력 Context가 됨
- **Field별 상한:** 분석 결과를 field별 크기 상한 안에서 재주입

예측 불가능한 문자열 팽창을 방어하는 Hard Limit 상한

Final Prompt 원칙: Prompt 전체를 잘라내지 않고, 가변 입력을 먼저 줄인 뒤 최종 크기만 확인합니다.

실습 검증 시나리오: 오늘 실습에서 확인할 것

STEP 01	STEP 02	STEP 03	STEP 04	STEP 05	STEP 06
확장 데이터 확인	**Postman 1차 실행**	**Langfuse 관찰**	**IDE 코드 확인**	**Postman 재실행**	**Langfuse 비교**
누적 Runbook/History	동일 STANDARD 요청	개선 전 input token	Top N + 크기 상한	동일 요청 재전송	개선 전/후 token 비교

// CONTROLLED COMPARISON BASELINE Pure Context Budget Verification

동일 요청 (Request)
order-service timeout 동일 페이로드 유지

동일 경로 (Route)
STANDARD_ANALYSIS 경로 변경 없음

동일 호출 (2 Calls)
Analysis + Recommendation 2회 호출 일치

검증 목표: route나 LLM 호출 횟수를 바꾸지 않고, **Context 통제 정책만으로 나타나는 순수 input token 절감 효과**를 검증합니다.

*핵심 검증 지표: Input Token

🏁 오늘 정리 & 다음 수업 안내

TODAY SUMMARY

Context Budget으로 비용 통제

- **데이터 축적 문제:** 데이터가 늘어날수록 LLM에 전달되는 Context도 함께 커질 수 있음
- **선택량 통제 (Selection):** Runbook 중복 제거와 severity별 Top N으로 전달 개수 제한
- **크기 통제 (Size):** 외부 입력과 이전 LLM 분석 결과의 재주입 크기 제한
- **재관찰 검증:** 같은 요청을 다시 실행하고 Langfuse에서 input token 감소 확인

UP NEXT LECTURE

다음 세션 미리보기 (수업 11)

입력 Context의 양은 통제했지만, LLM이 생성한 출력이 항상 애플리케이션이 요구하는 구조와 계약을 지키는 것은 아닙니다.

Cost Control: 얼마나 많은 Context를 허용할 것인가? (오늘 적용)
Quality Control: LLM이 생성한 출력을 어떤 기준으로 받아들일 것인가?(섹션 5)

Move to Quality Control ›