SECTION 5 | LECTURE 12

수업 12. Evaluator–Optimizer로 품질 루프 만들기

AI 출력을 평가하고 개선하기

⚠ 품질 검증의 다음 단계: 기본 계약을 통과해도 내용은 부실할 수 있다

BASIC OUTPUT CONTRACT

✓ PASS

수업 11의 검증 통과 상태

Java record 매핑 성공, 필수 필드 non-blank 확인, 리스트 개수 및 priority [1~3] 검증을 100% 통과한 구조

```
✓ JSON-only format valid
✓ situationSummary ≠ blank
✓ likelyCauses.size() ⩾ 1
✓ recommendedActions.size() == 3
✓ priority sequence: [1, 2, 3]
```

형식과 규격(Record)은 완벽히 성립된 상태

SEMANTIC QUALITY REALITY

? 부실한 내용

⚠ 계약은 지켰지만 조사에 쓸 수 없는 내용

비어 있지는 않으나 지나치게 일반적이고 추상적이어서 실제 운영자가 어떤 조치를 취해야 할지 알 수 없음

```
// likelyCauses[0] "시스템에 문제가 있을 수 있습니다." (DB 문제? 네트워크? 배포 버그? 조사 방향 부재)

// recommendedActions[0].actionTitle "시스템을 확인하세요." (개수 3개, 순위 1 맞춤. 그러나 실행 불가능한 조치)
```

문법적 유효성(Valid) ≠ 의미적 사용성(Usable)

❝ **핵심 질문:** 형식과 기본 계약을 통과했다는 이유만으로 **이 결과를 그대로 사용해도 될까?**

기본 계약 통과 ≠ 의미 품질 보장

평가 기준 수립: 의미 품질은 무엇을 기준으로 평가할까?

CRITERIA 01

근거 일치성

설명된 원인이 실제 제공된 증상 및 런북/이력 문맥과 합리적으로 연결되어 있는가?

- 제공된 근거와 연결되어 있는가?

확인된 사실과 추정을 명확히 구분

CRITERIA 02

구체성

추상적 표현을 배제하고 운영자가 즉시 조사 방향을 잡을 수 있는 수준인가?

- 실제 조사에 도움이 되는가?

없는 SQL·설정값 창작은 금지

CRITERIA 03

확신 수준 조절

제공된 정보의 한계를 인정하고 미확인 가능성을 단정적으로 표현하지 않는가?

- 확인되지 않은 사실을 단정하지 않는가?

과도한 확신(Overconfidence) 방어

CRITERIA 04

조치 적절성

추천 조치가 현재 Incident 및 분석 결과와 직결되며 실행 우선순위가 타당한가?

- 현재 Incident에 적절한 조치인가?

조사 방향과 액션의 논리적 결합

좋은 AI 출력의 정의: 단순히 문장이 길고 유려한 출력이 아니라, **근거에 맞고 실제 문제 해결에 도움이 되는 출력**입니다.

* 근거 없는 창작(Hallucination) 억제

품질 개선 루프: Evaluator–Optimizer로 평가하고 개선하기

// EVALUATOR-OPTIMIZER QUALITY CONTROL PIPELINE

Evaluate → Optimize → Re-Evaluate → Bounded Decision



EVALUATOR 무엇이 문제인지 평가

4대 기준(근거, 구체성, 확신, 조치)에 따라 미달 사항을 지적하고 수정 방향을 도출

OPTIMIZER 평가 결과를 바탕으로 개선

기존 출력을 처음부터 다시 쓰지 않고, Evaluator의 구체적 지적 사항을 반영해 수정

APPLICATION 수정 횟수와 종료 통제

무제한 루프를 원천 차단(수정 최대 1회). 재평가 실패 시 명시적 상태로 안전 종료

통제 설계 핵심: 수정은 **최대 1회만 허용**하며, 품질 기준을 충족하지 못하더라도 무제한 재수정으로 비용·지연을 폭증시키지 않습니다.

* Bounded Loop Governance

실습 검증 시나리오: 오늘 실습에서 확인할 것

STEP 01. IDE **구조 살펴보기**

기존 품질 통제 기반에 Evaluator/Optimizer 추가 구조 확인

STEP 02. POSTMAN + LOG **품질 개선 실험**

Analysis & Action 품질 미달 유도 후 개선 루프 동작 관찰

STEP 03. UNIT TEST **NOT_RESOLVED 검증**

재평가 실패 시 추가 호출 없이 즉시 종료되는 정책 검증

STEP 04. LANGFUSE **Span Tree 추적**

생성 → 평가 → 수정 → 재평가 전체 LLM 호출 트리 확인

// 3 EXPECTED QUALITY CONTROL OUTCOMES

Deterministic Application Governance

PASSED	최초 생성 결과가 의미 품질 4축을 모두 만족	[추가 수정 호출 0건 · 즉시 채택]
IMPROVED	1차 미달(NEEDS_REVISION) → Optimizer 수정 후 재평가 통과	[수정된 결과로 안전하게 교체]
NOT_RESOLVED	재평가 재실패 또는 계약 파기 → 추가 수정 차단 명시적 종료	[품질 미해결 상태 플래그 기록]

실습의 본질: 품질을 마법처럼 완벽히 보장하는 실습이 아니라, **품질을 평가하고 개선하는 과정을 애플리케이션이 통제하는 실습**입니다.

🏁 오늘 정리 & 다음 수업 안내

TODAY SUMMARY

Evaluator–Optimizer

🔄 의미 품질 평가와 루프 제어 완결

의미 품질 분리: 기본 계약(형태) 검증을 넘어 내용의 실질적 유용성 평가

4대 평가 기준: 근거 일치성, 구체성, 확신 수준 조절, 조치 적절성

책임의 명확화: Evaluator(평가) → Optimizer(수정) → Re-Evaluator(재평가)

종료 정책 통제: 무제한 루프 차단(최대 1회) 및 NOT_RESOLVED 상태 명시

통제 결론: AI가 평가하고 수정하더라도, **수정 횟수와 최종 결과 채택 여부는 애플리케이션이 결정**합니다.

UP NEXT LECTURE

🛡️ 다음 세션 미리보기 (리스크 통제)

품질 기준을 완벽히 통과한 추천이라도, 기술적으로 그럴듯하다는 이유만으로 그대로 외부에 전달하거나 실행해도 될까요?

Lesson 12 (품질 통제): 추천 내용이 근거에 맞고 실제 조사에 쓸 만한가?
Next Lesson (리스크 통제): 서비스 중단 등 위험한 조치인가? 조직 정책에 맞는가?

TRANSITION: QUALITY → RISK 위험 추천 식별, 승인 정책 및 안전한 응답 전달 제어

Move to Risk Control ›